

Lab 6: Apache Hive

L'objectif de ce TP est de :

- ◆ installation d'apache Hive
- ◆ Première utilisation d'apache Hive
- ◆ Réaliser des requêtes analytiques

Apache Hive est un software **datawarehouse** conçu pour lire, écrire et gérer de grands ensembles de données extraits du système de fichiers distribué d'Apache Hadoop (HDFS). En effet, il ne s'agit pas d'une base de données complète. Il ne stocke que les métadonnées et les données sont stockées uniquement dans HDFS. Ainsi, chaque requête écrite par l'utilisateur est convertie en code MapReduce qui interagit ensuite avec HDFS. Hive peut être utilisé comme système OLAP (Online Analytical Processing).

Hive est fourni avec HiveServer2, une interface serveur dotée de sa propre interface de ligne de commande (CLI) appelée **Beeline (client JDBC)**, qui permet de se connecter à Hive,

I. Installation Apache Hive

- Pull l'image depuis dockerHub : <https://hub.docker.com/r/apache/hive/tags>. La dernière image est 4.0.0-alpha-2

```
docker pull apache/hive:4.0.0-alpha-2
```

```
C:\Users\hp>docker pull apache/hive:4.0.0-alpha-2
4.0.0-alpha-2: Pulling from apache/hive
4f4fb700ef54: Pull complete
56a130901b37: Pull complete
eddb431f2fc: Pull complete
9d948bbdc842: Pull complete
239b6597911f: Pull complete
ee7a22f107a6: Pull complete
cd30f3d1e783: Pull complete
1a2de4cc9431: Pull complete
1efc276f4fff: Pull complete
a2f2f93da482: Pull complete
60930a9c0895: Pull complete
b237b9d3d33a: Pull complete
d2421c7a4bbf: Pull complete
Digest: sha256:69e482fdcebb9e07610943b610baea996c941bb36814cf233769b8a4db41f9c1
Status: Downloaded newer image for apache/hive:4.0.0-alpha-2
docker.io/apache/hive:4.0.0-alpha-2
```

Pour une configuration rapide, démarrer HiveServer2 avec le Metastore « embedded » (SGBD Derby comme BD metastore)

- Lancer ensuite les démons yarn et hdfs:

```
C:\Users\hp>docker run -v ~/Documents/hadoop_project/:/shared_volume -d -p 10000:10000 -p 10002:10002 -p 9083:9083 --env
SERVICE_NAME=hiveserver2 --name hiveserver2-standalone apache/hive:4.0.0-alpha-2
22e98cae016d3b79d2c6174dd02c788e32c578fc8117b037ac0d6e87799d12f

C:\Users\hp>docker ps
CONTAINER ID        IMAGE               COMMAND             CREATED            STATUS              PORTS
NAMES
22e98cae016        apache/hive:4.0.0-alpha-2   "sh -c /entrypoint.sh"   About a minute ago   Up About a minute   0.0.0.0:9083->9083/tcp, [::]:9083->9083/tcp, 0.0.0.0:10000->10000/tcp, [::]:10000->10000/tcp, 0.0.0.0:10002->10002/tcp, [::]:10002->10002/tcp   hiveserver2-standalone

C:\Users\hp>
```

- Pour accéder à HiveServer2 web via le navigateur via

<http://localhost:10002>

The screenshot shows the HiveServer2 web interface. At the top, there's a navigation bar with links like Home, Local logs, Metrics Dump, Hive Configuration, Stack Trace, Liap Daemons, and Configure logging. Below the navigation bar, there's a section titled "HiveServer2". Underneath it, there are three main sections: "Active Sessions", "Open Queries", and "Last Max 25 Closed Queries", each with a table header and some data rows.

User Name	IP Address	Operation Count	Active Time (s)	Idle Time (s)
Total number of sessions: 0				

User Name	Query	Execution Engine	State	Opened Timestamp	Opened (s)	Latency (s)	Drilldown Link
Total number of queries: 0							

User Name	Query	Execution Engine	State	Opened (s)	Closed Timestamp	Latency (s)	Drilldown Link
Last Max 25 Closed Queries							

II. Première utilisation beeline

Pour se connecter à serveur hive **hiveserver2**, on peut utiliser à l'invité de commande **Beeline** en fournissant une adresse IP et le port sur la chaîne d'URL de connexion JDBC. (Par défaut, le serveur écoute sur le port=10000)

- Accéder au shell du conteneur hiveserver2-standalone

```
C:\Users\DELL>docker exec -it hiveserver2-standalone bash
hive@bfb991da4f72:/opt/hive$ hadoop fs -ls
```

- HDFS est souvent déjà démarré dans les configurations Docker par défaut. Vérifier que HDFS est opérationnel :

```
hadoop fs -ls
```

```
:~\Users\hp>docker exec -it hiveserver2-standalone bash
hive@22e98caea016:/opt/hive$ hadoop fs -ls
Found 16 items
rw-r--r-- 1 root root 22349 2022-07-10 09:19 LICENSE
rw-r--r-- 1 root root 230 2022-07-10 09:19 NOTICE
rw-r--r-- 1 root root 29213 2022-07-10 09:19 RELEASE_NOTES.txt
lrwxr-xr-x - root root 4096 2023-05-02 18:52 bin
lrwxr-xr-x - root root 4096 2023-05-02 18:52 binary-package-licenses
rwxr-xr-x - hive root 4096 2025-11-02 02:06 conf
rwxr-xr-x - root root 4096 2023-05-02 18:52 contrib
rwxr-xr-x - root root 4096 2023-05-02 18:52 data
rw-r--r-- 1 hive hive 19959 2025-11-02 02:06 derby.log
rwxr-xr-x - root root 4096 2023-05-02 18:52 examples
rwxr-xr-x - root root 4096 2023-05-02 18:52 hcatalog
rwxr-xr-x - root root 4096 2023-05-02 18:52 jdbc
rwxr-xr-x - hive hive 4096 2025-11-02 02:06 metastore_db
rwxr-xr-x - root root 4096 2023-05-02 18:52 lib
rwxr-xr-x - hive hive 4096 2025-11-02 02:06 scratch_dir
rwxr-xr-x - root root 4096 2023-05-02 18:52 scripts
hive@22e98caea016:/opt/hive$
```

- visualiser le contenu du fichier de configuration **hive-site.xml** dans **/opt/hive/conf/**

```

hive@22e98cae016:/opt/hive$ cat /opt/hive/conf/hive-site.xml
<?xml version="1.0" encoding="UTF-8"?>
<!--
    Licensed to the Apache Software Foundation (ASF) under one or more
    contributor license agreements. See the NOTICE file distributed with
    this work for additional information regarding copyright ownership.
    The ASF licenses this file to You under the Apache License, Version 2.0
    (the "License"); you may not use this file except in compliance with
    the License. You may obtain a copy of the License at

        http://www.apache.org/licenses/LICENSE-2.0

    Unless required by applicable law or agreed to in writing, software
    distributed under the License is distributed on an "AS IS" BASIS,
    WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
    See the License for the specific language governing permissions and
    limitations under the License.
-->
<configuration>
```

```
-->
<configuration>    <!--
    <property>
        <name>hive.server2.enable.doAs</name>
        <value>false</value>
    </property>
    <property>
        <name>hive.tez.exec.inplace.progress</name>
        <value>false</value>
    </property>
    <property>
        <name>hive.exec.scratchdir</name>
        <value>/opt/hive/scratch_dir</value>
    </property>
    <property>
        <name>hive.user.install.directory</name>
        <value>/opt/hive/install_dir</value>
    </property>
    <property>
        <name>tez.runtime.optimize.local.fetch</name>
        <value>true</value>
    </property>
    <property>
        <name>hive.exec.submit.local.task.via.child</name>
        <value>false</value>
    </property>
    <property>
        <name>mapreduce.framework.name</name>
        <value>local</value>
    </property>
```

- Accéder au shell de hive beeline en utilisant la commande suivante : login « **scott** » avec mot de passe « **tiger** »)

```
beeline -u jdbc:hive2://localhost:10000 scott tiger
```

- afficher les bases de données disponibles:

```

0: jdbc:hive2://localhost:10000> show databases ;
INFO : Compiling command(queryId=hive_20251102015937_0ebab8ab-8b14-4ba4-ab5a-249c60ca8e87): show
databases
INFO : Semantic Analysis Completed (retrial = false)
INFO : Created Hive schema: Schema(fieldSchemas:[FieldSchema(name:database_name, type:string, com
ent:from deserializer)], properties:null)
INFO : Completed compiling command(queryId=hive_20251102015937_0ebab8ab-8b14-4ba4-ab5a-249c60ca8e
87); Time taken: 3.304 seconds
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Executing command(queryId=hive_20251102015937_0ebab8ab-8b14-4ba4-ab5a-249c60ca8e87): show
databases
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20251102015937_0ebab8ab-8b14-4ba4-ab5a-249c60ca8e
87); Time taken: 0.126 seconds
+-----+
| database_name |
+-----+
| default      |
+-----+
1 row selected (4.274 seconds)
```

III. Analyse de données de réservation d'hôtels

Dans ce TP, nous allons travailler sur un ensemble de données concernant les réservations d'hôtels. L'objectif principal est de manipuler, analyser et extraire des informations pertinentes sur les clients, les hôtels et leurs réservations. Pour ce faire, nous utiliserons Apache Hive pour stocker et interroger les données. Les données sont disponibles dans trois fichiers :

1. Créer la base de données

- Créer la base de données hotel_booking ;

```
CREATE DATABASE hotel_booking;
USE hotel_booking;
```

- Lister le contenu du répertoire /opt/hive/data/warehouse. Qu'est ce que vous remarquez ?

```
C:\Users\DELL>docker exec -it hiveserver2-standalone /bin/bash
hive@bfb991da4f72:/opt/hive$ ls -l /opt/hive/data/warehouse
total 4
drwxr-xr-x 2 hive hive 4096 Nov  2 02:03 hotel_booking.db
```

2. Créer les tables

- Créer les tables pour stocker les informations des clients et des hôtels.
- Pour employer les partitions et les buckets, il faudra commencer par activer les propriétés suivantes :

```
0: jdbc:hive2://localhost:10000> set hive.exec.dynamic.partition=true;
No rows affected (0.162 seconds)
```

```
No rows affected (0.012 seconds)
0: jdbc:hive2://localhost:10000> set hive.exec.dynamic.partition.mode=nonstrict;
No rows affected (0.013 seconds)
```

```
CREATE TABLE clients ( client_id INT, nom STRING, email STRING,
telephone STRING )
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
STORED AS TEXTFILE;
```

Créer la table ***reservations*** avec une partition par ***date_debut*** pour optimiser les requêtes en fonction des dates.

3. Charger les données dans les tables

- Charger les données dans la table clients et hotels.
 -


```

0: jdbc:hive2://localhost:10000> LOAD DATA LOCAL INPATH '/shared
volume/DATSETS_HIVE/hotels.txt' INTO TABLE hotels;
INFO : Compiling command(queryId=hive_20251102024847_f22f1b69-6
7d0-42da-9816-e9ef0d2f5d8c): LOAD DATA LOCAL INPATH '/shared_vol
ume/DATSETS_HIVE/hotels.txt' INTO TABLE hotels
INFO : Semantic Analysis Completed (retrial = false)
INFO : Created Hive schema: Schema(fieldSchemas:null, propertie
s:null)
INFO : Completed compiling command(queryId=hive_20251102024847_
f22f1b69-67d0-42da-9816-e9ef0d2f5d8c); Time taken: 0.076 seconds
INFO : Concurrency mode is disabled, not creating a lock manage
r
INFO : Executing command(queryId=hive_20251102024847_f22f1b69-6
7d0-42da-9816-e9ef0d2f5d8c): LOAD DATA LOCAL INPATH '/shared_v
olume/DATSETS_HIVE/hotels.txt' INTO TABLE hotels
INFO : Starting task [Stage-0:MOVE] in serial mode
INFO : Loading data to table default.hotels from file:/shared_v
olume/DATSETS_HIVE/hotels.txt
INFO : Starting task [Stage-1:STATS] in serial mode
INFO : Executing stats task
INFO : Table default.hotels stats: [numFiles=1, numRows=0, tota
lSize=852, rawDataSize=0, numFilesErasureCoded=0]
INFO : Completed executing command(queryId=hive_20251102024847_
f22f1b69-67d0-42da-9816-e9ef0d2f5d8c); Time taken: 0.606 seconds
No rows affected (0.717 seconds)

```

- Charger les données dans les tables reservations

	VERTICES		MODE		STATUS	TOTAL	COMPLETED	RUNN
	ING	PENDING	FAILED	KILLED				
Map 1	0	0	0	0	SUCCEEDED	1	1	
Reducer 2	0	0	0	0	SUCCEEDED	1	1	
Reducer 3	0	0	0	0	SUCCEEDED	1	1	
VERTICES:	03/03	[=====>]				100%	ELAPSED TI	
ME:	5.87 s							

4. Utiliser des partitions et des buckets

- Nous allons modifier la table ***hotels*** pour ajouter des partitions par ***ville*** et utiliser des buckets pour la table des réservations par ***client id*** afin d'optimiser les jointures.

VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	
Map 1	container	RUNNING	1	0	1	0	0	0	
Reducer 2	container	INITED	1	0					
INITED	1	0							
VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	
Map 1	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 2	container	RUNNING	1	0					
INITED	1	0							
VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	
Map 1	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 2	container	SUCCEEDED	1	1					
SUCCEEDED	1	1							
VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	
Map 1	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 2	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 3	container	SUCCEEDED	1	1	0	0	0	0	
VERTICES: 03/03	[=====>>]	100%	ELAPSED TIME:	2.28 s					
VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	default.hotels_partitioned partition
Map 1	container	SUCCEEDED	1	1	0	0	0	0	11-02_03-00-03_238_742629207061085
Reducer 2	container	SUCCEEDED	1	1					
SUCCEEDED	1	1							
VERTICES	MODE	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED	
Map 1	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 2	container	SUCCEEDED	1	1	0	0	0	0	
Reducer 3	container	SUCCEEDED	1	1	0	0	0	0	
VERTICES: 03/03	[=====>>]	100%	ELAPSED TIME:	3.21 s					

- Charger les tables créées.
- Lister le contenu du répertoire /opt/hive/data/warehouse/hotel_booking.db/. Qu'est ce que vous remarquez ?

5. Utilisation de requêtes simples

- Lister tous les clients
- Lister tous les hôtels à Paris
- Lister toutes les réservations avec les informations sur les hôtels et les clients

6. Requêtes avec jointures

- Afficher le nombre de réservations par client
- Afficher les clients qui ont réservé plus que 2 nuitées
- Afficher les Hôtels réservés par chaque client
- Afficher les noms des hôtels dans lesquels il y a plus qu'une réservation.
- Afficher les noms des hôtels dans lesquels il y a pas de réservation.

7. Requêtes imbriquées

- Afficher les clients ayant réservé un hôtel avec plus de 4 étoiles
- Afficher le Total des revenus générés par chaque hôtel

8. Utilisation de fonctions d'agrégation avec partitions et buckets

- Revenus totaux par ville (partitionnée)
- Nombre total de réservations par client (bucketed)

9. Nettoyage et suppression des données

Supprimer les tables créées précédemment.

10. Script hql

Refaire le même traitement en organisant le code en trois scripts HiveQL distincts :

1. **Creation.hql** : Contient les commandes pour créer la base de données, les tables (clients, hôtels, réservations), ainsi que les partitions et les buckets si nécessaires.
2. **Loading.hql** : Contient les instructions pour charger les données depuis les fichiers texte (clients.txt, hotels.txt, reservations.txt) dans les tables Hive.
3. **Queries.hql** : Inclut toutes les requêtes SQL précédentes, telles que les jointures, les agrégations et les requêtes imbriquées.

Ces scripts doivent être exécutés dans l'ordre pour reproduire entièrement le traitement